

Mitigación del Olvido en Modelos de Generación de Texto mediante Replay

Manfred Jones Sanabria

Ing. en Computación

Tecnológico de Costa Rica (TEC)

Alajuela, Costa Rica

<https://orcid.org/0009-0006-5521-5764>

Jeaustin Obando Arias

Ing. en Computación

Tecnológico de Costa Rica (TEC)

Alajuela, Costa Rica

<https://orcid.org/0009-0009-8028-8086>

Angello Vividea García

Ing. en Computación

Tecnológico de Costa Rica (TEC)

Heredia, Costa Rica

<https://orcid.org/0009-0002-6485-1165>

Abstract: This study explores the use of continual learning techniques to mitigate catastrophic forgetting in text generation models, specifically for the task of automatic text simplification in Spanish. The pre-trained T5-small model is used and evaluated in a sequential learning setting with two tasks: simplification and machine translation. The experiment comprises three phases: training on simplification, training on translation without continual learning techniques, and training with Replay as a mitigation strategy. Results show that the model forgets how to simplify after learning the new task without Replay, but is able to retain this ability when Replay is applied. The study concludes that Replay is an effective alternative to preserve prior knowledge in multi-task text generation scenarios.

Keywords: continual learning, text simplification, catastrophic forgetting, replay

Resumen: Este estudio explora el uso de técnicas de aprendizaje continuo para mitigar el olvido catastrófico en modelos de generación de texto, específicamente en la tarea de simplificación automática de texto en español. Se utiliza y evalúa el modelo preentrenado T5-small en un escenario de aprendizaje secuencial con dos tareas: simplificación y traducción automática. El experimento consta de tres fases: entrenamiento en simplificación, entrenamiento en traducción sin técnicas de aprendizaje continuo y entrenamiento aplicando Replay como estrategia de mitigación. Los resultados muestran que el modelo olvida cómo simplificar tras aprender la nueva tarea sin Replay, pero logra conservar esta capacidad cuando Replay es utilizado. El estudio concluye que Replay es una alternativa efectiva para preservar el conocimiento previo en escenarios multitarea de generación de texto.

Palabras clave: aprendizaje continuo, simplificación de texto, olvido catastrófico, Replay

1. INTRODUCCIÓN

La simplificación automática de texto busca transformar textos complejos en versiones más accesibles, manteniendo su significado. Esta tarea es clave para mejorar la comprensión lectora en diversos contextos, pero en español sigue siendo un desafío por la falta de recursos y estudios específicos.

Los modelos de lenguaje de gran tamaño (LLMs), han mostrado gran potencial en tareas de generación de texto. Sin embargo, cuando se actualizan con nuevos datos, suelen sufrir olvido catastrófico, perdiendo rendimiento en tareas previamente aprendidas. En este trabajo exploramos cómo el aprendizaje continuo (CL), mediante técnicas como Replay, puede mitigar este problema en la tarea de simplificación en español.

Los objetivos principales de esta investigación son: (1) evaluar el rendimiento del modelo en la tarea de simplificación antes y después de ser expuesto a una nueva tarea (traducción automática), (2) medir el grado de *olvido catastrófico* observado tras el aprendizaje secuencial sin CL, y (3) analizar la efectividad del enfoque con *Replay* para preservar el conocimiento previo.

2. MARCO TEÓRICO

2.1. Aprendizaje continuo

Para llegar al nivel de Inteligencia Artificial General (AGI), los LLMs deben ser capaces de recordar tareas y procesos. Sin embargo esto se dificulta en la práctica, ya sea por secuencia de tareas no definida claramente o impredecibilidad. El concepto de aprendizaje continuo surge a partir de la habilidad para aprender nuevas tareas sin olvidar cómo llevar a cabo tareas previamente entrenadas [1].

2.2. Olvido catastrófico

El término de olvido catastrófico (catastrophic forgetting) ocurre cuando la información de una tarea ya aprendida se olvida a medida que nueva información relacionada a la tarea en cuestión se incorpora. Esto se da especialmente cuando el modelo está aprendiendo secuencialmente una serie de tareas, y los pesos relevantes para la tarea A, son modificados para cumplir con lo requerido por la tarea B [1].

2.3. Dilema de plasticidad-estabilidad

Relacionado al concepto de olvido catastrófico, los LLMs y modelos de aprendizaje se enfrentan al problema de requerir plasticidad para aprender nueva información, pero al mismo tiempo necesitan estabilidad para poder retener el conocimiento previo. Si hay mucha plasticidad, el sistema aprende fácilmente, pero olvida lo anterior, dando paso al

olvido catastrófico [2]. Si hay mucha estabilidad, es posible que el modelo no tenga la capacidad de adaptarse al nuevo conocimiento. Dado este dilema, un enfoque planteado basado en el cerebro humano es la memoria dual, donde existe una memoria de corto plazo dedicada a la información nueva, y una de largo plazo para retener todo lo aprendido. Esta idea ha dado paso a estrategias de aprendizaje como la consolidación de pesos y replay.

2.4. Elastic weight consolidation

Un algoritmo usado para evitar el olvido catastrófico es elastic weight consolidation (EWC), donde se impone un tipo de penalización en los parámetros críticos de tareas anteriores, para que estos no puedan ser modificados conforme se aprenden nuevas tareas [1]. Para esto, EWC usa la matriz de Fisher para calcular la importancia de cada peso y aplica la penalización que actúa como un tipo de resorte elástico y restringen que estos pesos se mantengan cerca de sus valores ya establecidos. Este algoritmo está inspirado en la consolidación sináptica del cerebro y cómo se reduce la plasticidad de conocimientos anteriormente adquiridos a la hora de aprender cosas nuevas.

2.5. Experience replay

Otro algoritmo usado para el aprendizaje continuo es reproducción (experience replay), donde se almacenan y reutilizan conceptos aprendidos en tareas pasadas a medida que se entrena el modelo con nuevas tareas. Del mismo modo, se basa en cómo el cerebro humano al reproducir memorias, ayudando a evitar el olvido y consolidar la memoria. El replay logra un balance entre plasticidad y estabilidad, al mantener la capacidad de aprender cosas nuevas sin olvidar lo anterior [3].

2.6. Dataset FEINA

Se utilizará como base el conjunto de datos presentado en el artículo *A Novel Dataset for Financial Education Text Simplification in Spanish*, que consta del dataset FEINA (Financial Education IN Academic texts). Este dataset está diseñado específicamente para la simplificación de textos en español en el dominio de la educación financiera, y está disponible a través de la plataforma Hugging Face [4]. FEINA contiene ejemplos pareados de textos originales y sus correspondientes versiones simplificadas, en las columnas Segmento y Propuesta.

2.7. Métrica ROUGE

ROUGE (Recall-Oriented Understudy for Gisting Evaluation) es un conjunto de métricas ampliamente utilizado para evaluar tareas de generación de texto, como la simplificación y el resumen. [5] Estas métricas comparan el texto generado automáticamente con uno o más textos de referencia, midiendo el grado de superposición entre ambos en distintos niveles de granularidad. En tareas de simplificación, se consideran valores ROUGE superiores a 0.4 como indicativos de buena correspondencia con las referencias.

Las variantes de ROUGE empleadas en este trabajo son:

- **ROUGE-1**: mide la coincidencia de unigramas (palabras individuales) entre la predicción y la referencia.
- **ROUGE-2**: mide la coincidencia de bigramas (pares consecutivos de palabras) entre la predicción y la referencia.
- **ROUGE-L**: mide la longitud de la subsecuencia común más larga (Longest Common Subsequence, LCS) entre la predicción y la referencia, capturando similitudes en la estructura global del texto.
- **ROUGE-Lsum**: variante de ROUGE-L optimizada para la evaluación de resúmenes, también aplicable a simplificación de texto.

2.8. Métrica BLEU

BLEU (Bilingual Evaluation Understudy) es una métrica desarrollada originalmente para evaluar sistemas de traducción automática, la cual compara la predicción generada con la traducción de referencia, bajo la premisa de que cuanto más se aproxime la predicción a las referencias humanas, mejor será su calidad [6].

El resultado es un valor entre 0 y 1. En la práctica, un BLEU superior a 0.6 es considerado excelente, aunque es poco realista esperar una puntuación cercana a 1, dado que incluso muy pocas traducciones humanas llegan a este valor, y puede indicar overfitting del modelo [7].

3. ESTADO DEL ARTE

3.1. Fundamentos y Enfoques Principales en Continual Learning

El olvido catastrófico y esfuerzos en aprendizaje continuo han motivado el desarrollo de estrategias para preservar el conocimiento adquirido al introducir nuevas tareas. El concepto central es que un sistema debe retener y transferir conocimientos de forma eficiente, similar al aprendizaje humano.

Entre las primeras propuestas se encuentra Elastic Weight Consolidation, que ha sido pionera en la categoría de estrategias de regularización, marcó un hito al presentar un enfoque viable y teóricamente sólido para mitigar el olvido catastrófico en redes neuronales.

La eficiencia de EWC se demuestra especialmente en dominios similares, donde los parámetros críticos tienden a ser compartidos. Sin embargo, esta técnica enfrenta limitaciones en escenarios multi-dominio o cuando la secuencia de tareas es extensa. La acumulación de restricciones y la aproximación de la matriz de Fisher se vuelven obstáculos importantes para su escalabilidad [1].

Otra línea importante de investigación emergente en esta etapa inicial incluye Synaptic Intelligence (SI) y Memory Aware Synapses (MAS), que también buscan preservar conocimiento a nivel de parámetros, pero con diferentes mecanismos de estimación de importancia. Estas estrategias comparten el enfoque de penalizar actualizaciones que afecten parámetros relevantes, aunque difieren en la forma en que identifican dichos parámetros.

Además de los métodos basados en regularización, emergen los métodos de “replay”, como Gradient Episodic Memory

(GEM), que utilizan ejemplos seleccionados de tareas anteriores para evitar el olvido. GEM introduce un sistema de proyección del gradiente para no deteriorar el rendimiento en tareas pasadas, representando una forma activa de preservar conocimiento.

Durante la etapa de consolidación (2019–2021), se profundiza en la complejidad de las arquitecturas. Un trabajo destacado es el de von Oswald et al., que propone el uso de hypernetworks para generar dinámicamente los parámetros de redes específicas por tarea, utilizando embeddings aprendidos [8]. Esta arquitectura permite almacenar solo representaciones latentes de cada tarea, reduciendo el costo de memoria.

La propuesta de *hypernetworks* es relevante en contextos donde la identidad de la tarea es conocida y se desea minimizar el almacenamiento de datos. La regularización en el espacio de salidas también ayuda a evitar interferencias negativas entre tareas, aportando robustez al modelo [8].

Sin embargo, el uso de hypernetworks implica limitaciones, como la necesidad de conocer el identificador de la tarea, lo que puede ser restrictivo en escenarios más realistas o sin supervisión. Además, la escalabilidad con muchas tareas puede verse comprometida por el tamaño del modelo generador.

El trabajo de von Oswald también abre la puerta a nuevas formas de combinar generación de parámetros con métodos de regularización, dando lugar a arquitecturas híbridas. Estas estrategias se perfilan como soluciones prometedoras para mantener un equilibrio entre estabilidad y plasticidad.

Por último, en esta etapa se consolidan métricas clave como la Average Accuracy, Backward Transfer (BWT), y Forgetting Measure, que se vuelven estándares para evaluar desempeño en aprendizaje continuo. Estas métricas permiten capturar aspectos diversos como la retención de conocimiento, la habilidad de aprender nuevas tareas y el balance entre olvidar y generalizar.

3.2. Continual Learning en Entornos Multi-Dominio

Conforme avanza el campo, se reconocen las limitaciones de las técnicas tradicionales frente a la complejidad de entornos multi-dominio. El aprendizaje continuo ya no solo debe retener tareas similares, sino adaptarse a dominios completamente diferentes en estilo, distribución o representación semántica. Este cambio demanda métodos que sean agnósticos a la identidad de la tarea o que puedan generalizar más allá de contextos homogéneos.

Una de las primeras incursiones específicas en escenarios multi-dominio es el trabajo de Lee et al. sobre Domain-Incremental Learning, que propone evaluar algoritmos sin acceso explícito al identificador de tarea. Este cambio de paradigma obliga a los modelos a reconocer la distribución implícita del dominio, lo cual representa un reto mayor que el continual learning tradicional.

En esta línea, el trabajo de Wang et al. introduce el enfoque Learning to Prompt for Continual Learning (L2P), una solución novedosa basada en el uso dinámico de prompts aprendidos para guiar la representación del input en un modelo preentrenado [9]. Esta técnica evita el uso de buffers, no

requiere conocer la tarea ni los límites de tareas (task boundaries), y logra excelentes resultados en benchmarks como Split CIFAR-100 y DomainNet.

El modelo L2P mantiene un conjunto de prompts codificados como pares clave-valor, donde cada input selecciona su prompt ideal mediante atención. Esto permite capturar señales contextuales específicas de cada dominio sin incurrir en sobresaturación del modelo base. Además, al no depender de ejemplos previos, resulta especialmente útil para escenarios con restricciones de privacidad o almacenamiento [9].

Una fortaleza crítica del enfoque de L2P es su aplicabilidad a dominios distintos. El sistema aprende representaciones especializadas sin necesidad de reentrenar toda la red, lo cual permite adaptar el comportamiento del modelo sin pérdida de eficiencia. En entornos como visión por computador con múltiples estilos visuales o análisis de sentimiento en diferentes registros lingüísticos, esta capacidad resulta clave.

No obstante, el uso de prompts implica desafíos como la gestión del prompt pool y la necesidad de un modelo base robusto. Además, existe la posibilidad de que la selección de prompts no generalice a dominios muy alejados de los observados durante el entrenamiento. Estas limitaciones motivan investigaciones hacia métodos adaptativos o prompts generativos.

Una extensión natural de L2P podría incluir su integración con foundation models o modelos multimodales, como los transformadores entrenados a gran escala. Estos modelos ya incorporan capacidades de transferencia implícita, y combinarlos con prompts dinámicos puede aumentar su adaptabilidad sin incurrir en catástrofe del olvido.

Los enfoques actuales también abordan la evaluación desde una perspectiva más realista. Datasets como DomainNet y VLCS, con dominios visuales y contextuales variados, permiten evaluar cómo responde un modelo a cambios significativos en el estilo y distribución. Estos benchmarks impulsan el desarrollo de algoritmos que generalicen en múltiples dimensiones, no solo en secuencias artificiales.

El aprendizaje continuo federado (Federated Continual Learning) representa otra tendencia emergente. En este caso, se busca aprender continuamente desde múltiples clientes, cada uno asociado a un dominio diferente, sin centralizar los datos. Esta configuración presenta oportunidades únicas pero también desafíos en cuanto a privacidad, desbalance de tareas y sincronización entre nodos.

En términos de métricas, se comienza a evaluar no solo el rendimiento promedio, sino la estabilidad bajo dominios cambiantes, la adaptabilidad sin task-id y la robustez frente a dominios previamente no vistos. Estas dimensiones requieren nuevas métricas compuestas que combinen desempeño, olvido y capacidad de generalización entre dominios.

Finalmente, los estudios recientes revelan una dirección clara hacia métodos task-agnostic, adaptativos y multi-modales, donde la clave no solo es retener, sino evolucionar. Esto implica entender el aprendizaje continuo como un proceso flexible, integrador y consciente del contexto, más allá del paradigma secuencial clásico.

4. MÉTODO PROPUESTO

En este trabajo se plantea la siguiente pregunta de investigación: *¿es posible mitigar el olvido catastrófico en un modelo de simplificación de texto mediante el uso de Replay, en un escenario de aprendizaje secuencial con tareas distintas?*

De acuerdo con los objetivos definidos en la introducción, se plantea un método experimental basado en aprendizaje continuo sobre un modelo de generación de texto.

El experimento se estructura a partir del entrenamiento secuencial de un modelo en dos tareas distintas:

- **Tarea A: Simplificación de texto**, utilizando el conjunto de datos FEINA.
- **Tarea B: Traducción de texto**, a partir de un dataset derivado de FEINA, con pares de traducción español → inglés.

El diseño parte de las siguientes hipótesis:

1. El modelo, entrenado inicialmente en la tarea A, logrará aprender a simplificar textos.
2. Al entrenar el modelo en la tarea B sin técnicas de *Continual Learning*, se producirá un deterioro en la capacidad de simplificación (*forgetting*).
3. La técnica de *Replay*, mediante la inclusión parcial de datos de la tarea A durante el entrenamiento en la tarea B, permitirá conservar parcial o totalmente la capacidad de simplificación mientras se aprende la nueva tarea de traducción.

El esquema de evaluación contempla las diferentes fases de entrenamiento del modelo en las tareas, y se utilizarán ejemplos directos y métricas para medir el desempeño del modelo después de cada fase, permitiendo medir tanto el aprendizaje de nuevas tareas como el impacto del *Replay* en la mitigación del *forgetting*.

5. DISEÑO EXPERIMENTAL

5.1. Herramientas utilizadas

El experimento se implementó en un entorno reproducible de Google Colab, utilizando aceleración por GPU (tipo T4). Se emplearon las bibliotecas *Transformers*, *datasets*, *evaluate*, *sentencepiece* y *PyTorch*. Los datos se organizaron en archivos *.xlsx*, con ejemplos correspondientes a las tareas de simplificación y traducción.

5.2. Criterios de selección de muestras

Se utilizaron dos conjuntos de datos tabulares con columnas *Segmento* (texto original) y *Propuesta* (texto simplificado o traducido). Para la tarea B (traducción), se generó un nuevo conjunto de datos a partir de FEINA, traduciendo los textos originales al inglés. La traducción se realizó de forma automática utilizando la función *TRANSLATE* en Excel, con el fin de obtener pares de ejemplos español → inglés adecuados para la tarea de traducción. Las muestras se procesaron como sigue:

- Eliminación de entradas con valores nulos o no textuales.
- Creación de ejemplos en el formato "prefix: Segmento" → "Propuesta", con el objetivo de

indicar explícitamente al modelo la tarea que debe realizar y diferenciar entre múltiples tareas durante el entrenamiento y la inferencia. Se utilizaron los siguientes prefijos:

- **Tarea A:** Prefijo "simplify:"
- **Tarea B:** Prefijo "translate:"
- División de los datos en conjuntos de entrenamiento (80 %) y prueba (20 %), utilizando `train_test_split` con semilla `random_state=42`.
- Se utilizó la totalidad de los 5313 ejemplos del conjunto.

5.3. Diseño técnico

El modelo base seleccionado fue T5-small, un modelo secuencial de generación de texto preentrenado, elegido por su balance entre capacidad y eficiencia computacional. La técnica de *Replay* se implementó mediante la construcción de un conjunto de entrenamiento combinado (50 % de los ejemplos de la tarea A + 100 % de los ejemplos de la tarea B), con los ejemplos conservando los prefijos y mezclados aleatoriamente.

El entrenamiento se realizó en tres fases:

1. **Fase 1 (After A):** Entrenamiento en la tarea A (simplificación de texto) con el dataset FEINA.
2. **Fase 2 (After B no CL):** Entrenamiento en la tarea B (traducción), sin *Replay*, partiendo del modelo entrenado en A y el dataset traducido.
3. **Fase 3 (After B with CL):** Entrenamiento en la tarea B con *Replay*, partiendo del modelo entrenado en A, utilizando el conjunto combinado de datos.

5.4. Controles aplicados

Para asegurar la validez de las comparaciones entre condiciones:

- Se utilizó el mismo modelo base T5-small en todas las fases.
- Se aplicaron hiperparámetros constantes: batch size, número de épocas, longitud máxima de secuencia.
- Se mantuvieron constantes los conjuntos de prueba para ambas tareas en todas las fases.

5.5. Técnicas de análisis y evaluación

El rendimiento del modelo se evaluó mediante:

- **ROUGE**, para la tarea de simplificación (tarea A).
- **BLEU**, para la tarea de traducción (tarea B).
- Ejemplos prácticos del modelo donde **Input** es el texto que recibe, **Target** es el texto de referencia y **Prediction** es la salida generada.

Los ejemplos métricas se registraron en los siguientes momentos:

- **After A:** Tarea A después del entrenamiento en simplificación.
- **After B no CL:** Tarea B después del entrenamiento en traducción, y Tarea A evaluada nuevamente para medir *forgetting*.

- **After B with CL:** Tarea B y Tarea A después del entrenamiento con *Replay*, para evaluar mitigación del *forgetting*.

Para obtener las métricas, después de cada fase se evalúan las predicciones del modelo para las tareas, iterando sobre los datos definidos de prueba y usando una función que envía la entrada, con el prefijo respectivo, al modelo y recibe su predicción.

5.6. Replicabilidad del estudio

El procedimiento completo se documentó en el Notebook en Google Colab. Los pasos incluyeron:

- Preparación de datos.
- Definición de la clase `TextDataset`.
- Carga y configuración del modelo `T5-small`.
- Entrenamiento secuencial con y sin *Replay*.
- Evaluación mediante las métricas ROUGE y BLEU.

6. RESULTADOS Y DISCUSIÓN

Esta sección presenta los resultados obtenidos a lo largo de las tres fases de entrenamiento del modelo. Se analizan ejemplos de salida textual, gráficas de desempeño y métricas cuantitativas, con el objetivo de evaluar el impacto del aprendizaje continuo mediante *Replay* en la preservación de la tarea de simplificación.

Fase 1: Entrenamiento en la tarea A (simplificación)

En la primera fase, el modelo fue entrenado exclusivamente con el conjunto de datos `FEINA`, enfocado en simplificación de texto. La Figura 1 muestra un ejemplo de predicción generada por el modelo, la cual evidencia una simplificación efectiva y coherente.

Input: simplify: En poco tiempo, si continúas haciendo los pagos regularmente, los montos adeudados disminuirán.
Target: En poco tiempo, los montos adeudados bajarán.
Prediction: En poco tiempo, si continúas haciendo los montos adeudados disminuirán.

Figura 1: Ejemplo de simplificación Fase 1 (After A)

Las métricas ROUGE obtenidas se visualizan en la Figura 2, alcanzando valores altos en sus variaciones. Esto confirma que el modelo aprendió correctamente a simplificar y que los valores están dentro del rango esperado para esta tarea.




Figura 2: Métricas Rouge de Tarea A en Fase 1 (After A)

Fase 2: Entrenamiento en la tarea B (traducción) sin CL

Posteriormente, el modelo fue entrenado en la tarea B, la traducción al inglés. La Figura 3 muestra que el modelo logra realizar traducciones adecuadas, lo cual se refleja también en una puntuación BLEU aceptable (≈ 0.43).

Input: translate: Las operaciones financieras incluyen intereses debido a un principio básico del dinero: un dólar hoy es preferible a un dólar mañana.
Target: Financial transactions include interest due to a basic principle of money: a dollar today is preferable to a dollar tomorrow.
Prediction: Financial operations include interest based on a basic principle of money: a dollar today is preferable to a dollar.

Figura 3: Ejemplo de traducción Fase 2 (After B no CL)

Sin embargo, al evaluarlo nuevamente en la tarea de simplificación (tarea A), el modelo ya no genera versiones simplificadas, sino que continúa traduciendo, como muestra la Figura 4. Las métricas ROUGE caen drásticamente (ver Figura 5), evidenciando un caso claro de *olvido catastrófico*. Aunque el modelo fue expuesto al prefijo `simplify:`, no logra ejecutar correctamente la tarea correspondiente, y reproduce el comportamiento aprendido más recientemente.

Input: simplify: Además, Las exportaciones no pagan IVA.
Target: Además, las exportaciones no pagan el impuesto al valor agregado.
Prediction: In addition, exports do not pay VAT.

Figura 4: Ejemplo de simplificación Fase 2 (After B no CL)




Figura 5: Métricas Rouge de Tarea A en Fase 2 (After B no CL)

Fase 3: Aplicación de *Replay* (CL)

En la tercera fase, se aplica la técnica de *Replay*, entrenando al modelo con un conjunto combinado: 100 % del dataset de traducción y 50 % del dataset de simplificación. Los ejemplos fueron mezclados aleatoriamente, manteniendo sus prefijos respectivos.

Gracias a esta estrategia, el modelo logra conservar el conocimiento de ambas tareas. En la Figura 7 se observa que ahora sí puede simplificar correctamente, mientras que en la Figura 6 se mantiene la calidad de la traducción. Las métricas ROUGE, mostradas en la Figura 8, recuperan valores similares

a los de la Fase 1, confirmando que el conocimiento sobre simplificación fue preservado.

Input: translate: Por ejemplo, supongamos que vas a invertir \$30 al mes en acciones de la compañía XYZ.
Target: For example, let's say you're going to invest \$30 a month in shares of company XYZ.
Prediction: For example, let's say you're going to invest \$30 at least in shares of the company XYZ.

Figura 6: Ejemplo de traducción Fase 3 (After B with CL)

Input: simplify: Por ejemplo, los solicitantes deben reunir los requisitos según una "prueba de insuficiencia de medios".
Target: Por ejemplo, los solicitantes deben reunir los requisitos según una prueba de insuficiencia de medios.
Prediction: Por ejemplo, los solicitantes deben reunir los requisitos segn una prueba de insuficiencia de medios.

Figura 7: Ejemplo de simplificación Fase 3 (After B with CL)




Figura 8: Métricas Rouge de Tarea A en Fase 3 (After B with CL)

Resumen comparativo

El Cuadro I resume las métricas obtenidas en cada fase y se observa que:

- El modelo aprende a simplificar de forma efectiva tras la Fase 1.
- El olvido catastrófico ocurre tras la Fase 2, al exponerse únicamente a la tarea de traducción.
- La técnica de Replay (Fase 3) permite recuperar el desempeño en simplificación sin afectar la capacidad de traducción.

Cuadro I: Comparación de métricas por fase y tarea

Fase → Métrica	ROUGE-1	ROUGE-2	ROUGE-L	BLEU
After A (Tarea A)	0.69	0.52	0.65	–
After B no CL (Tarea A)	0.03	0.00	0.03	–
After B with CL (Tarea A)	0.70	0.55	0.66	–
After B no CL (Tarea B)	–	–	–	0.42
After B with CL (Tarea B)	–	–	–	0.43

Por tanto, se valida la hipótesis central de este estudio: la inclusión parcial de datos previos mediante Replay es una

estrategia efectiva para mitigar el olvido catastrófico en modelos de generación de texto entrenados de forma secuencial en tareas distintas.

7. CONCLUSIONES DE LA INVESTIGACION

Los resultados de esta investigación confirman que el modelo T5-small puede aprender la tarea de simplificación de texto en español con buenos niveles de rendimiento según métricas ROUGE.

Sin embargo, el entrenamiento en una nueva tarea sin técnicas de CL genera un deterioro significativo en el rendimiento anterior, validando el fenómeno de olvido catastrófico.

Frente a esto, la técnica de Replay, aun aplicada de manera básica, permite reducir el impacto del olvido, demostrando que es una alternativa viable y eficiente en contextos multitécnica.

Además, este estudio demuestra la necesidad de integrar estrategias de aprendizaje continuo en aplicaciones reales con múltiples tareas, especialmente en entornos de generación de texto donde la transferencia y retención del conocimiento son fundamentales.

Finalmente, se destaca la utilidad de utilizar datasets bien estructurados y métricas robustas para evaluar estas técnicas, sentando una base para futuras investigaciones en simplificación de texto en español mediante aprendizaje continuo.

REFERENCIAS

- [1] J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwińska *et al.*, "Overcoming catastrophic forgetting in neural networks," *Proc. Natl. Acad. Sci. USA*, vol. 114, no. 13, pp. 3521–3526, Apr. 2017. [Online]. Available: <https://arxiv.org/pdf/1612.00796v2>
- [2] M. Mermillod, A. Bugaiska, and P. Bonin, "The stability-plasticity dilemma: investigating the continuum from catastrophic forgetting to age-limited learning effects," *Frontiers in Psychology*, vol. 4, 2013. [Online]. Available: <https://doi.org/10.3389/fpsyg.2013.00504>
- [3] D. Rolnick, A. Ahuja, J. Schwarz, T. P. Lillicrap, and G. Wayne, "Experience Replay for Continual Learning," 2019. [Online]. Available: <https://arxiv.org/pdf/1811.11682>
- [4] N. Perez-Rojas, S. Calderon-Ramirez, M. Solis-Salazar, M. Romero-Sandoval, M. Arias-Monge, and H. Saggion, "A Novel Dataset for Financial Education Text Simplification in Spanish," *arXiv:2312.09897*, 2023. [Online]. Available: <https://huggingface.co/datasets/saul1917/FEINA>
- [5] F. Chiusano, "Two minutes NLP — Learn the ROUGE metric by examples," *NLPlanet*, Apr. 13, 2022. [Online]. Available: <https://medium.com/nlplanet/two-minutes-nlp-learn-the-rouge-metric-by-examples-f179cc285499>
- [6] F. Chiusano, "Two minutes NLP — Learn the BLEU metric by examples," *NLPlanet*, Jan. 11, 2022. [Online]. Available: <https://medium.com/nlplanet/two-minutes-nlp-learn-the-bleu-metric-by-examples-df015ca73a86>
- [7] K. Doshi, "Foundations of NLP Explained - Bleu Score and WER Metrics," *Towards Data Science*, May 09, 2021. [Online]. Available: <https://towardsdatascience.com/foundations-of-nlp-explained-bleu-score-and-wer-metrics-1a5ba06d812b>
- [8] J. von Oswald, C. Henning, J. Sacramento, and B. Nessler, "Continual learning with hypernetworks," *arXiv preprint arXiv:1906.00695*, 2020. [Online]. Available: <https://arxiv.org/pdf/1906.00695v4>
- [9] X. Wang, Y. Huang, Y. Zhang, and H. Zhao, "Learning to prompt for continual learning," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 139–149. [Online]. Available: <https://arxiv.org/pdf/2112.08654v2>